

CRIPTOLOGÍA Y SEGURIDAD DE LOS DATOS

MASTER DE CIBERSEGURIDAD Y CIBERINTELIGENCIA

ETSINF - UPV

Criptoanálisis

CRIPTOGRAFÍA POST CUÁNTICA

1. Introducción

El objetivo en este trabajo consiste en abordar la solución de problemas en los que se basan los recientes estándares de criptografía post cuántica. No se conocen algoritmos eficientes para obtener la solución de estos problemas es alta, por lo que, para tallas grandes del problema, se espera que este sea irresoluble independientemente de la capacidad computacional que se disponga.

El objetivo de este trabajo es que el estudiante entienda la estructura de estos problemas y por lo tanto la razón de la dificultad de estos. Para ello se plantean instancias de tamaño creciente, que permiten proporcionar estrategias de resolución (en el límite por fuerza bruta), investigar e implementar las aproximaciones existentes, plantear alternativas y testar su comportamiento. Como hemos comentado poco antes, este proceso debería concluir con la comprensión profunda y la percepción de las bases de solución algorítmica de los problemas en los que se basa la criptografía post cuántica.

– oOo –

IMPORTANTE:

El listado de problemas no se incluye en este documento. Se publican en el sitio de la asignatura.

En este documento se hace referencia a instancias de problemas, en ningún momento a los algoritmos que los consideran y/o resuelven. Investigar cuales son estos algoritmos, estudiarlos y utilizarlos es el objetivo último de este trabajo

Se valorarán especialmente soluciones originales (propias) de los autores del trabajo. En este sentido, será necesario justificar la hipótesis en la que se basa la solución.

Este documento describe brevemente los problemas, no debe considerarse como documento suficiente para estudiar las características de estos. Se sugiere utilizar el material recomendado en la asignatura para una descripción más extensa.

2. Celosías (lattices)

Dado un conjunto $\{v_i : 1 \leq i \leq k\}$ de vectores linealmente independientes $\mathbb{R}^n$, se define una celosía como el conjunto:

$$\mathcal{L} = \{a_1v_1 + a_2v_2 + \dots + a_kv_k : a_i \in \mathbb{Z}\} \subset \mathbb{R}^n$$

El problema de, dado el conjunto de vectores que definen una celosía, encontrar el punto más cercano al origen se conoce como *SVP* (de su acrónimo en inglés Shortest Vector Problem). En espacios n dimensionales grandes o con vectores poco ortogonales este problema se considera difícil incluso en un escenario post cuántico. Otro problema que se considera difícil en este contexto es, dados una celosía de dimensión n y un punto de $\mathbb{R}^n$, encontrar el punto de la celosía más cercano a él o *CVP* (también de su acrónimo en inglés Closest Vector Problem).

2.1. GGH

Goldreich, Goldwasser y Halevi¹ proponen un algoritmo de cifrado de clave asimétrica (GGH) aprovechando la posibilidad de construir, para cualquier dimensión, bases de vectores equivalentes poco ortogonales que generan la misma celosía. Aunque en su formulación inicial este algoritmo no se considera seguro, es esencialmente la misma de un método seguro. Este método es importante para entender otros métodos basados en celosías.

GGH: Generación de la clave

Considérese una base B de vectores n dimensionales y una matriz unimodular U ($\det(U) = \pm 1$). A partir de estas se calcula:

$$B' = UB,$$

con lo que las claves pública y privada son respectivamente $\langle B' \rangle$ y $\langle B, U \rangle$.

¹Goldreich, Oded; Goldwasser, Shafi; Halevi, Shai (1997). «Public-key cryptosystems from lattice reduction problems». CRYPTO '97: Proceedings of the 17th Annual International Cryptology Conference on Advances in Cryptology. London: Springer-Verlag. pp. 112–131.




Figura 1: A la izquierda se muestra la celosía en 2D definida por los vectores $\langle 3, 1 \rangle$ y $\langle -1, 4 \rangle$. En la derecha la generada por $\langle 5, 19 \rangle$ y $\langle 3, 14 \rangle$.

Ejemplo 1 Consideremos el conjunto de vectores $\langle 3, 1 \rangle$ y $\langle -1, 4 \rangle$ y la celosía que estos definen en $\mathbb{R}^2$, si tomamos como matriz unimodular la siguiente:

$$U = \begin{pmatrix} 3 & 4 \\ 2 & 3 \end{pmatrix},$$

la clave privada la forman las matrices:

$$\left\langle B = \begin{pmatrix} 3 & 1 \\ -1 & 4 \end{pmatrix}, U = \begin{pmatrix} 3 & 4 \\ 2 & 3 \end{pmatrix} \right\rangle$$

siendo la clave pública:

$$\left\langle B' = UB = \begin{pmatrix} 5 & 19 \\ 3 & 14 \end{pmatrix} \right\rangle$$

La Figura 1 muestra ambas bases y la celosía que generan.

GGH: Cifrado

Considerando el mensaje a cifrar como un vector n dimensional, el cifrado de x se obtiene como:

$$c = xB' + e,$$

donde e es un vector n dimensional que introduce ruido (*error*) en el cifrado. Este ruido debe ser limitado ya que si fuera excesivo no permitiría el descifrado correcto del mensaje.

Ejemplo 2 Continuando con el Ejemplo 1, si se induce un error $e = \langle -1, 1 \rangle$ el cifrado del mensaje $x = \langle 7, 3 \rangle$ se obtiene como:

$$c = xB' + e = \begin{pmatrix} 7 & 3 \end{pmatrix} \begin{pmatrix} 5 & 19 \\ 3 & 14 \end{pmatrix} + \begin{pmatrix} -1 & 1 \end{pmatrix}$$

con lo que el criptograma que se obtiene es $c = \langle 43, 176 \rangle$.

GGH: Descifrado

Al recibir un criptograma c , se calcula el producto de este por la matriz B^{-1} . Si se considera cómo se obtuvo el criptograma se tiene que:

$$cB^{-1} = (xB' + e)B^{-1} = xUBB^{-1} + eB^{-1},$$

Si el ruido que se indujo en el cifrado fue limitado, la componente eB^{-1} puede eliminarse por redondeo (el llamado *Babai round*). Con lo que el primer paso sería:

$$y = \text{Round}(cB^{-1}),$$

para a continuación obtener el mensaje utilizando la inversa de la matriz unimodular (que devuelve las coordenadas a la base privada).

$$x = yU^{-1}.$$

Ejemplo 3 Continuamos con los ejemplos anteriores y desciframos el criptograma $c = \langle 43, 176 \rangle$. El primer producto obtiene:

$$cB^{-1} = (43 \quad 176) \frac{1}{13} \begin{pmatrix} 4 & -1 \\ 1 & 3 \end{pmatrix} = (26,769 \quad 37,308)$$

con lo que redondeando tenemos $y = \langle 27, 37 \rangle$. El producto con U^{-1} :

$$yU^{-1} = (27 \quad 37) \begin{pmatrix} 3 & -4 \\ -2 & 3 \end{pmatrix} = (7 \quad 3)$$

devuelve el mensaje original.

– oOo –

Notese que si el error en el cifrado hubiera sido un poco mayor, por ejemplo $e' = \langle -2, 2 \rangle$, el criptograma obtenido hubiera sido $c = \langle 42, 177 \rangle$ que no permite obtener el mensaje original (se deja la comprobación como ejercicio).

GGH: Seguridad

Existe una forma de transformar la base pública del protocolo GGH que hace factible atacar el descifrado de criptogramas. No se proporcionan detalles ya que es objetivo de una de las tareas propuestas.

Una forma de endurecer el cifrado es considerar una reducción módulo en los cálculos. En efecto esta aproximación hace más difícil el descifrado, incluso en ocasiones para el receptor legítimo del mensaje. Se incluyen tareas para analizar este hecho.

Pese a todo, el algoritmo GGH y las celosías abrieron la puerta a una técnica derivada (el aprendizaje con errores o LWE (del acrónimo en inglés *Learning With Errors*), base de algunos de los recientes estándares de algoritmos post cuántum.

2.2. Learning with errors

Propuesto en 2005 por Oded Regev, *Learning With Errors*² (LWE) se basa en la dificultad de resolver sistemas de ecuaciones cuando se introduce un determinado nivel de ruido. En su trabajo, Regev demuestra que resolver LWE en el caso promedio es, al menos, tan difícil como resolver problemas difíciles en retículas en el peor caso.

Un protocolo LWE considera un sistema de ecuaciones con k incógnitas:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots a_{1k}x_k \equiv b_1 & (\text{mód } n) \\ a_{21}x_1 + a_{22}x_2 + \dots a_{2k}x_k \equiv b_2 & (\text{mód } n) \\ \vdots \\ a_{k1}x_1 + a_{k2}x_2 + \dots a_{kk}x_k \equiv b_k & (\text{mód } n) \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \dots a_{mk}x_k \equiv b_m & (\text{mód } n) \end{cases}$$

En esta configuración bastan k ecuaciones para obtener el valor de las incógnitas (esto correspondería a una aproximación de learning *without errors*). Sin embargo, la inclusión de un determinado ruido aleatorio en cada una de las ecuaciones:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots a_{1k}x_k \approx b_1 + e_1 & (\text{mód } n) \\ a_{21}x_1 + a_{22}x_2 + \dots a_{2k}x_k \approx b_2 + e_2 & (\text{mód } n) \\ \vdots \\ a_{k1}x_1 + a_{k2}x_2 + \dots a_{kk}x_k \approx b_k + e_k & (\text{mód } n) \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \dots a_{mk}x_k \approx b_m + e_m & (\text{mód } n) \end{cases} \quad (1)$$

convierte el problema de obtener los valores de las incógnitas en difícil de resolver, complejidad que aumenta respecto el número de incógnitas y de ecuaciones.

En el trabajo original, Regev utiliza esta aproximación para proponer un sistema de cifrado de clave pública.

²O. Regev (2009). «On lattices, learning with errors, random linear codes, and cryptography». Journal of the ACM 56(6):34.

LWE: Generación de la clave

Puede construirse un método de clave asimétrica para la transmisión segura de una secuencia basado en LWE. El método considera un vector de k secretos:

$$S = (s_1, s_2, \dots, s_k)$$

y un conjunto de m errores limitados:

$$E = (e_1, e_2, \dots, e_m)$$

para construir un sistema L similar a (1) que constituiría la componente pública de la clave, siendo el vector S la componente privada. Notamos que el vector E debe mantenerse privada, sin embargo no es necesario mantenerla.

Ejemplo 4 *A partir de el vector $S = (4, 70, 0, 3)$, un vector de errores $E = (-3, 3, -2, 0, 2)$ y trabajando módulo 71, se puede generar el siguiente sistema con coeficientes aleatorios:*

$$\begin{cases} 70x_1 + 6x_2 + 25x_3 + 15x_4 \approx 32 & (\text{mód } 71) \\ 19x_1 + 51x_2 + 27x_3 + 32x_4 \approx 53 & (\text{mód } 71) \\ 53x_1 + 55x_2 + 51x_3 + 6x_4 \approx 31 & (\text{mód } 71) \\ 59x_1 + 46x_2 + 26x_3 + 51x_4 \approx 59 & (\text{mód } 71) \\ 23x_1 + 5x_2 + 36x_3 + 45x_4 \approx 11 & (\text{mód } 71) \end{cases}$$

Como se ha expuesto, el sistema es la componente pública del protocolo y el conjunto S la componente privada.

LWE: Cifrado

El protocolo propuesto por Regev considera exclusivamente el cifrado de un mensaje de un bit como prueba de concepto. El protocolo considera la selección aleatoria de algunas de las ecuaciones del sistema:

$$\begin{cases} a_{u1}x_1 + a_{u2}x_2 + \dots a_{uk}x_k \approx b_u + e_u & (\text{mód } n) \\ a_{v1}x_1 + a_{v2}x_2 + \dots a_{vk}x_k \approx b_v + e_v & (\text{mód } n) \\ \vdots \end{cases}$$

consideramos primero la suma de los coeficientes y los términos independientes de las ecuaciones seleccionadas (distinguimos en la notación el error, aunque la clave pública no lo hace):

$$\begin{cases} A_1 = a_{u1} + a_{v1} + \dots \text{mód } n \\ A_2 = a_{u2} + a_{v2} + \dots \text{mód } n \\ \vdots \\ A_k = a_{uk} + a_{vk} + \dots \text{mód } n \\ B = b_u + b_v + \dots + e_u + e_v + \dots \text{mód } n \end{cases}$$

con lo que la suma de las ecuaciones seleccionadas queda como:

$$A_1x_1 + A_2x_2 + \dots + A_kx_k \approx B \quad (2)$$

Notamos que el resultado considera el error acumulado incluido en las ecuaciones seleccionadas. Notamos también que es posible eliminar este error si se conoce el conjunto de valores secretos.

El cifrado de un bit considera el envío de una ecuación como criptograma. Esta ecuación es:

$$A_1x_1 + A_2x_2 + \dots + A_kx_k \approx B + (\lfloor n/2 \rfloor \cdot \text{bit}) \text{ mód } n \quad (3)$$

Ejemplo 5 *Continuando con el Ejemplo 4, seleccionamos las ecuaciones*

$$\begin{cases} 70x_1 + 6x_2 + 25x_3 + 15x_4 \approx 32 & (\text{mód } 71) \\ 53x_1 + 55x_2 + 51x_3 + 6x_4 \approx 31 & (\text{mód } 71) \end{cases}$$

cuya suma da como resultado:

$$52x_1 + 61x_2 + 5x_3 + 21x_4 \approx 63$$

que sería el criptograma en caso de querer transmitir un bit 0. En caso de que el mensaje fuera un bit 1, el criptograma sería:

$$52x_1 + 61x_2 + 5x_3 + 21x_4 \approx 43$$

ya que $63 + 35 \bmod 71 = 43$.

LWE: Descifrado

Dado un criptograma recibido:

$$C = \langle A_1x_1 + A_2x_2 + \dots + A_kx_k \approx B \rangle,$$

es posible considerar la componente secreta S (el vector de soluciones para las variables x_i) para obtener el resultado *real*, sin errores, de la ecuación. Considerando operaciones sobre matrices:

$$CS^T = R.$$

El cifrado del mensaje construye dos *polos* de valores. Un primer polo que, independientemente del criptograma, cifra un bit 0 con valores cercanos a R y un segundo, para un bit 1 que los cifra con valores lo más alejados posible (cercaños a la mitad del valor del módulo). Por lo tanto, si R y B están próximos, el mensaje transmitido es 0, por el contrario, si están alejados el mensaje es 1. Para determinar el umbral suele escogerse un valor de error máximo reducido que no ofrezca lugar a dudas en el descifrado.

Ejemplo 6 Continuando con los Ejemplos 4 y 5, trabajando módulo 71, consideramos los criptogramas:

$$41x_2 + 32x_3 + 53x_4 \approx 9$$

$$40x_1 + 36x_2 + 31x_3 + 1x_4 \approx 15$$

$$5x_1 + 60x_2 + 16x_3 + 51x_4 \approx 42$$

$$41x_1 + 62x_2 + 17x_3 + 21x_4 \approx 25$$

obtenidos seleccionando y sumando algunas ecuaciones en la componente pública.

Teniendo en cuenta el primer criptograma y la componente privada de la clave tenemos:

$$(0 \ 41 \ 32 \ 53) \begin{pmatrix} 4 \\ 70 \\ 0 \\ 3 \end{pmatrix} \text{mód } 71 = 47$$

que está apreciablemente alejado del 9 considerado en el criptograma, por lo que el bit transmitido es 1.

Repetimos el proceso para el resto de ecuaciones en el criptograma:

$$(40 \ 36 \ 31 \ 1) \begin{pmatrix} 4 \\ 70 \\ 0 \\ 3 \end{pmatrix} \text{mód } 71 = 56$$

$$(5 \ 60 \ 16 \ 51) \begin{pmatrix} 4 \\ 70 \\ 0 \\ 3 \end{pmatrix} \text{mód } 71 = 42$$

$$(41 \ 62 \ 17 \ 21) \begin{pmatrix} 4 \\ 70 \\ 0 \\ 3 \end{pmatrix} \text{mód } 71 = 23$$

que permite recuperar los bits 1, 0 y 0 ya que, respectivamente, el primero está alejado de 15, el segundo es cercano (de hecho igual) a 42 y el tercero es cercano a 25.

3. Evaluación

La evaluación del trabajo considera la solución de tareas propuestas en el sitio polifomat de la asignatura. Sin embargo, las meras soluciones de estas tareas no se considerarán a no ser que se atiendan las indicaciones que se

describen a continuación. Al final de la sección se describen las tareas y el criterio que define las categorías en las que se agrupan estas.

De forma general:

1 Considerando el peso de la memoria del trabajo en la nota final de la asignatura:

- No se aceptarán trabajos individuales o de grupos de más de cuatro personas.
- La memoria no deberá tener una longitud superior a 5 páginas, márgenes no superiores a 2,54 cm, fuente de tamaño 12 y espaciado simple.
- La memoria del trabajo deberá distinguir claramente secciones para: introducción, algoritmos, resolución de tareas y conclusiones. La presentación y estructura general del trabajo tendrá un peso del 15 %, la presentación de los algoritmos utilizados un peso del 30 %, las tareas resueltas un 40 % y las conclusiones un 15 %.

En relación con las tareas:

Las tareas resueltas supone 4/10 puntos en la nota del trabajo, teniendo esto presente:

- Se publican tareas de varios niveles. La elección de qué tareas resolver e incluir en la memoria es decisión de los miembros del grupo.
- Cada tarea de **nivel 1** resuelta tendrá una calificación de 0.3 puntos. No se podrá obtener una calificación superior a 1.4 punto con tareas de este nivel.
- Cada tarea de **nivel 2** resuelta tendrá una calificación de 0.5 puntos. No se podrá obtener una calificación superior a 1.8 puntos con tareas de este nivel.
- Cada tarea de **nivel 3** o superior resuelta tendrá una calificación de 1 punto. No hay límite a la puntuación obtenida con estas tareas salvo la general indicada al principio de la sección.

- No es necesario utilizar más de una alternativa de solución para resolver los ejercicios, aunque se tendrá en cuenta variedad de aproximaciones. En su caso, es importante mostrar cómo evoluciona el tiempo necesario para obtener una solución en función de la talla de los problemas.
- Una solución por fuerza bruta es factible siempre que se defiendan convenientemente las razones que llevan a esta aproximación.
- Cualquier recurso bibliográfico o tecnológico utilizado deberá constar convenientemente. En su caso, y del mismo modo (con formato de cita bibliográfica), deberán constar el/los LLMs (u otra tecnología basada en inteligencia artificial) y prompts utilizados. Deberá constar cómo se ha considerado el resultado.
- Resolver tareas de categoría 2 o superior relacionadas con las dos tareas (secciones) descritas en este documento implicará un bono (no superior al 20 %) sobre la nota obtenida por esas tareas.

Evaluación de tareas:

Es **importante** tener presente que, para considerar una solución:

- La memoria deberá **justificar claramente el algoritmo** utilizado, esto es, por qué el algoritmo resuelve el problema.
- La memoria deberá aportar justificación clara de **cómo el algoritmo resuelve el problema**, una traza breve pero clara que muestre resultados intermedios de la ejecución es suficiente.

Defensa de los trabajos:

- La no defensa del trabajo supone una calificación 0.
- Todos los miembros del grupo deberán estar presentes para la defensa. En caso de tener motivo justificado es posible reprogramar el momento de la defensa.
- La nota de la defensa no será superior a la nota del trabajo.
- El profesor decidirá en el momento de la defensa qué miembro del grupo (portavoz) que contestará las preguntas.

- La defensa será presencial y tendrá una duración aproximada de diez minutos por grupo.
- En la defensa el portavoz será el encargado de contestar las preguntas que se hagan sobre las tareas. Es decisión del profesor cambiar o no de portavoz durante la defensa.
- La nota obtenida por este portavoz será la que comparta todo el grupo.
- La defensa podrá implicar contestar a preguntas sobre los métodos utilizados para la resolución de las tareas.
- En una defensa correcta se espera que el portavoz justifique la conveniencia de utilizar el algoritmo seleccionado y explicar sus bases y comportamiento.

Tareas

En el sitio Poliformat de la asignatura se han publicado problemas de distinta dificultad relacionados con el cifrado GGH y LWE. El nombre del fichero identifica la tarea y el nivel (tier) de esta.

La estructura de los ficheros relacionados con el mismo problema es el mismo: ficheros CSV (o *space-delimited*), con líneas de comentarios precedidos del símbolo #. Cada fichero describe el formato de entrada, el problema a resolver y (en ocasiones) la solución al problema para que puedan testarse los algoritmos desarrollados.

Tier 0

Las tareas en esta categoría están orientadas a adquirir intuición en casos triviales del problema. En relación con el cifrado GGH, las tareas en esta categoría consideran la solución de los problemas SVP o CVP para celosías con bases ortogonales o casi ortogonales (cuya resolución es sencilla).

En relación con el cifrado LWE, las tareas en esta categoría consideran la ruptura de un sistema con un número de incógnitas reducido o con ruido inducido limitado.

Si bien estas tareas no se valoran en la nota del trabajo, se recomienda su implementación ya que, bien puede ser la base para abordar tareas más complejas, bien puede ser la base para una aproximación original.

Tier 1

En esta categoría se incluyen:

- Tareas que abordan problemas sencillos (en categorías anteriores) pero considerando un número elevado de dimensiones.
- Tareas GGH que consideran una base no ortogonal pero un número de dimensiones reducido. Estos problemas serían abordables incluso con soluciones por fuerza bruta.
- Tareas LWE de talla reducida que incluso podrían abordarse por fuerza bruta.

Tier 2

En esta categoría se incluyen tareas GGH o LWE abordadas en el nivel anterior pero que consideran un número mayor de dimensiones.

Tier 3 y/o 3+

En esta categoría se incluyen tareas con mayor grado de dificultad. Estas tareas tienen solución documentada pero, en ocasiones, necesitan una revisión de la literatura para su defensa con garantías.